

Pandas

심선영 교수

강의 목표

- ❖ Pandas 라이브러리를 학습하여 데이터 처리 기법을 익힌다.
- ❖ 데이터에 따른 척도의 종류를 이해한다.
- ❖ 데이터 가공 기법 (인코딩, 스케일링)을 실습을 통해 익힌다.

강의 목차

- ❖ Pandas 라이브러리
- ❖ 데이터에 따른 척도의 종류
- ❖ 데이터 가공
 - 데이터 인코딩
 - 데이터 스케일링

데이터 가공과 분석

데이터의 가공과 분석

Pandas 라이브러리

❖ Pandas 라이브러리

- 핵심 데이터타입은 2X2의 행렬구조인 DataFrame (데이터프레임)
- 데이터의 구조 파악 및 내용 확인
- 결측값 처리 (보정 or 삭제), 데이터 변환 및 결합 등의 데이터 가공
- Numpy의 수치 연산 기능 또는 Matplotlib/Seaborn과 같은 시각화 모듈을 활용, 데이터에 대한 이해를 높이고 예측에 유리한 형태로 가공함

Pandas 라이브러리

❖ <https://pandas.pydata.org/>

The screenshot shows the pandas documentation website in a web browser. The browser's address bar displays the URL `pandas.pydata.org/docs/getting_started/index.html#getting-started`. The page features the pandas logo and navigation links for 'Getting started', 'User Guide', 'API reference', 'Development', and 'Release notes'. A search bar is located on the left side of the page. The main content area is titled 'intro to pandas' and includes a section titled 'What kind of data does pandas handle?'. This section explains that pandas is used for tabular data and introduces the `DataFrame` object. Below the text, a diagram illustrates a `DataFrame` as a grid of cells, with a specific row and column highlighted and labeled 'row' and 'column' respectively. At the bottom of the page, there are buttons for 'To introduction tutorial' and 'To user guide'.

데이터에 따른 척도의 종류

데이터에 따른 척도의 종류

자료(데이터)에 따른 척도의 종류

❖ (!!)데이터를 탐색, 가공, 분석 하기 전에 먼저 알아야 할 것이 있음!

→ 데이터와 척도의 유형



데이터에 따른 척도의 종류

자료(데이터)에 따른 척도의 종류

❖ 명목 척도

- 측정된 값이 숫자가 아닌 '구분자'인 경우
- 예) 성별(남/녀), 지역 (서울,대전,대구,제주 등), 부서(마케팅,영업,기획 등) 등
- 회귀분석 시 더미변수(dummy variable) 활용

❖ 서열 척도

- 데이터 값이 순서나 순위를 표현하는 경우 (순위간 차이가 일정하지 않음.)
- 예) 브랜드 선호도 순위,반 등수 등
- 회귀분석에서 사용불가

데이터에 따른 척도의 종류

자료(데이터)에 따른 척도의 종류

❖ 등간 척도

- 순서가 있으며 순서 사이의 간격이 동일한 변수
- 예) 5점 리커르트, 온도
- 회귀분석 시 종속변수와 독립변수로 모두 사용 가능

❖ 비율 척도

- 등간 변수의 특성을 가지고 있으며 절대 영점을 가지고 있는 변수
- 사칙연산 가능 & 자료간 비율 계산 가능
- 예) 거리, 매출액, 길이, 무게
- 회귀분석 시 종속변수와 독립변수로 모두 사용 가능

데이터 가공 기법

데이터 가공

데이터 가공의 중요성

- ❖ 데이터 가공(전처리)은 머신러닝 알고리즘만큼 중요!
- ❖ 어떤 데이터가 입력되는냐에 따라 결과가 크게 달라지기 때문

데이터 가공

데이터 가공 기법들

❖ 결측값(NaN, Null) 처리

- 평균값 등으로 대체하거나 해당 변수를 drop

❖ 데이터 인코딩 - 문자열 값을 숫자형으로 변환 (카테고리형, 텍스트형 변수에 해당)

- 레이블 인코딩
- One-Hot 인코딩

❖ 스케일링

- 표준화
- 정규화

데이터 인코딩

❖ 레이블 인코딩

- 문자열 값을 숫자형 카테고리 값으로 변환
 - [TV, 냉장고, '선풍기'] → [0,1,2]
- 사이킷런의 **LableEncoder()** 로 수행
- 레이블 인코딩 후 숫자값이 부여되는데 이를 머신러닝에 바로 사용하면, 예측 성능이 떨어질 수 있음
 - 냉장고 1, 선풍기2 → 1보다 2가 크다는 의미가 부여되기 때문 (실제로는 단순한 구분용일 뿐인데..)
- 이러한 이유로 레이블 인코딩은 회귀분석과 같은 머신러닝에서 사용하지 않아야 함
- 레이블 인코딩의 이러한 문제점을 해결하기 위한 방법이 바로 " 원-핫 인코딩" 임!

데이터 인코딩

❖ 원-핫 인코딩

- feature 값의 유형에 따라 새로운 feature 를 추가하고 고유값에 해당하는 칼럼만 1을 표시, 나머지는 모두 0을 표시하는 방식
- Pandas의 `get_dummies( )` 또는 사이킷런의 `OneHotEncoder()` 로 수행
 - 원-핫 인코딩을 하기 전에 문자열 데이터는 반드시 숫자형 값으로 변환! (즉 레이블 인코딩을 먼저 수행!)

레이블 인코딩		원-핫 인코딩					
상품 분류	상품분류	TV	냉장고	믹서	선풍기	전자렌지	컴퓨터
TV	0	1	0	0	0	0	0
냉장고	1	0	1	0	0	0	0
전자렌지	4	0	0	0	0	1	0
컴퓨터	5	0	0	0	0	0	1
선풍기	3	0	0	0	1	0	0
선풍기	3	0	0	0	1	0	0
믹서	2	0	0	1	0	0	0
믹서	2	0	0	1	0	0	0

스케일링

❖ 스케일링의 목적

- feature들의 값을 있는 그대로 넣었을 때, 각 값의 평균과 분산, 최대 최소 값이 제각각
- feature간 비교/분석이 어렵고 따라서 학습 모델을 잘 만들지 못할 수 있음
- 표준화 또는 정규화를 통해 각 feature값의 분포나 범위를 제한해 줌으로써 모델의 학습 성능을 높일 수 있음

데이터 가공

스케일링

❖ 표준화

- 데이터 피쳐 각각을 평균이 0, 분산이 1인 표준 정규분포로 변화하는 것

$$x_{new} = \frac{x - \mu}{\sigma}$$

표준화 공식

데이터 가공

스케일링

❖ 정규화 (Normalization)

■ 데이터를 0과 1사이의 값으로 변환함

❖ 서로 다른 피처의 크기를 동일한 크기로 변환해 주는 개념

■ 예) 가격 0원 50,000,000원

■ 예) 몸무게 0~100kg

❖ 모두 동일한 크기 단위로 비교 하기 위해 최소 0~최대1값으로 변화하는 것

$$x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

정규화 공식

Wrap Up
