

회귀 알고리즘 및 실습

심선영 교수

강의 목표

- ❖ 회귀 모델의 개념과 유형을 이해한다.
- ❖ 선형 회귀 모델의 개념을 이해하고 실습해 본다.
- ❖ 회귀 트리 모델의 개념을 이해하고 실습해 본다.
- ❖ 회귀를 위한 앙상블 모델의 개념을 이해하고 실습해 본다.
- ❖ 회귀 오차의 개념 및 평가지표를 학습하고 실습해 본다.


강의 목차

- ❖ 회귀 모델 소개
- ❖ 선형 회귀 모델
- ❖ 회귀 트리 모델
- ❖ 회귀 앙상블 모델
- ❖ 회귀 모델 평가 지표

회귀모델 소개

분류와 회귀의 비교

- ❖ 분류 (classification) – 어떤 집단에 속하는 지 판별해 내는 것
- ❖ 회귀 (regression) – 주어진 값에 대한 결과값을 예측하는 것



회귀 모델

❖ 요인(변수)들 간의 인과관계 분석하여 결과를 예측하는 통계적 기법

- 원인이 되는 요인들을 찾아내어 결과와의 관계를 분석
- 발생한 사건이나 현상을 설명하기 위해 사용
- 해당 원인 요인을 이용하여 결과를 예측
 - 예) IQ와 성적, 흡연과 암 발생률 등

❖ 회귀 모델의 변수

- 종속변수(dependent variable) 혹은 반응변수(response variable): 다른 변수의 영향을 받는 변수
→ Target
- 독립변수(independent variable) 혹은 설명 변수(explanatory variable): 다른 변수에 영향을 주는 변수
→ Feature

회귀 모델의 유형

구분		회귀 모델
feature의 수	한 개	단순 회귀 (Simple Regression)
	두 개 이상	다중 회귀 (Multiple Regression)
데이터의 형태	선형	일반 선형 회귀 (General Linear Regression)
	비선형	다항 회귀 (Polynomial Regression)

선형 회귀 모델

선형 회귀 모델

단순 회귀(Simple Regression)

❖ 단순 선형 회귀 (simple linear regression)

$$Y = W_0 + W_1 X$$

Y_i = 종속변수 (target)
 X_i = 독립변수 (feature)
 W_0 = 절편 (intercept)
 W_1 = 회귀계수 (coefficient)


❖ 회귀 모델의 설명력: R^2

■ 종속변수의 분산(변동성) 가운데 회귀모델에 의해 설명되는 비율

■ $R^2 = \frac{\text{예측값의 분산}}{\text{실제값의 분산}} \quad (0 \sim 1)$

■ 예) 개인소득- 종속변수, 경력- 독립변수

- R-제곱 = 0.83: 개인소득 분산의 83%가 경력에 의해 설명된다는 의미



선형 회귀 모델

다중 회귀(Multiple Regression)

❖ 다중 선형 회귀 (multiple linear regression)

- 결과값(Y)을 예측하기 위해 두 개 이상의 독립변수(feature)를 사용

$$Y = W_0 + W_1 X_1 + W_2 X_2 + \dots + W_n X_n$$





회귀 트리 모델

회귀 트리의 기본 개념

❖ 회귀 계수를 구하는 **회귀 함수** 대신 **트리**를 사용하는 하는 회귀 모델


❖ 분류를 위한 결정 트리 방식과 유사

- 데이터 셋을 X값의 균일도를 반영한 지니 계수에 따라 분할
- 말단 노드별 소속된 데이터의 평균값을 구해서 최종 결정 값으로 사용!
 - 결정 트리: 말단 노드에 속한 특정 클래스의 레이블을 결정
 - 회귀 트리: 말단 노드에 속하는 데이터의 평균값으로 예측



회귀 트리 예시

- 선형회귀는 직선으로 예측 회귀선을 표현
- 회귀트리의 경우 분할되는 노드에 따라 가지를 만들면서 계단 형식의 회귀선이 생성



트리(Tree) 알고리즘의 활용

- Tree기반의 모든 알고리즘은 회귀와 분류에서 동시에 사용됨
 - DecisionTree, RandomForest, GBM 등
- Tree의 생성이 CART(Classification And Regression Trees) 알고리즘에 기반하고 있기 때문
- 사이킷런(sikit-learn) Estimator Class

알고리즘	분류 Estimator Class	회귀 Estimator Class
Decision Tree	DecisionTreeClassifier	DecisionTreeRegressor
Random Forest	RandomForestClassifier	RandomForestRegressor
ExtraTree	ExtraTreesClassifier	ExtraTreesRegressor
XGBoost	XGBClassifier	XGBRegressor
LightGBM	LGBMClassifier	LGBMRegressor

회귀 앙상블 모델

회귀 앙상블 모델


앙상블 모델

- 여러 개의 모델을 결합하여 사용하는 모델
 - Regression, Classification 모두 지원
 - 회귀(단일 모델들의 결과를 평균하여 예측), 분류(단일 모델들의 결과에 투표하여 예측)
- 머신러닝의 앙상블은 크게 배깅(Bagging)과 부스팅(Boosting) 두 가지로 구분
 - 둘다 상대적으로 약한 Decision Tree를 조합
 - 단, 배깅(Bagging)은 병렬적으로 여러 개의 독립적 결정트리를 만들어 결합한다면(평균)
 - 부스팅(Boosting)은 직렬적으로 1개의 모델을 계속 업데이트 시켜가는 방식

앙상블 모델 - 배깅

배깅 (Bagging)

- Bagging: Bootstrap Aggregation
 - Bootstrap으로 각 결정트리를 학습시킨 후 그 결과물을 집계(Aggregation)하는 방법



앙상블 모델 - 배깅

배깅 (Bagging)

- 부트스트랩(Bootstrap)

- 샘플을 여러 번 뽑는 방법
- n 개의 결정트리가 서로 다른 데이터로 학습토록 하기 위하여
- 원본 데이터셋에서 중복을 허용하여 무작위로 m 개의 데이터를 선택하는 기법



앙상블 모델 - 배깅

배깅 (Bagging)

- 랜덤 포레스트 (Random Forest)


- 결정트리(decision tree)를 n개 결합한 모델
- 데이터 분할 최적화를 위해 부트스트랩 기법을 이용

- 엑스트라 트리 리그레션 (ExtraTree Regression)

- 랜덤 포레스트의 변형 형태
- Extremely Randomized 학습법 (샘플수, feature 설정이 모두 random)
- 부트스트랩은 사용하지 않음: (bootstrap=False)로 파라미터 초기값 설정
- 그 외는 랜덤 포레스트와 동일한 앙상블 모델
- 랜덤 포레스트는 데이터를 최적 분할하지만(bootstrap) 엑스트라 트리는 임의 분할하여 랜덤 포레스트보다 속도가 빠름

부스팅 (Boosting)

- 상대적으로 약한 Decision Tree를 조합해서 사용
- 약한 예측 모형들의 학습 에러에 가중치를 두고, 순차적으로 다음 학습 모델에 반영하여 점점 강한 예측모형을 만드는 것




부스팅 (Boosting)

- **XGBoost (eXtreme Gradient Boosting)**
 - Boosting 기법을 이용하여 구현한 대표적 알고리즘
 - 성능과 자원 효율이 좋아서 많이 사용되는 알고리즘
- **LightGBM (Light Gradient Boosting Model)**
 - Boosting 기법을 이용하여 구현한 최신 알고리즘
 - 학습시간이 짧아 XGBoost 보다 속도가 빠름(light)
 - 파라미터의 수가 매우 많음


회귀 모델 평가 지표

회귀 모델 평가 지표

회귀 오차



여러 회귀 모델 중
오차가 가장 적은 모델



❖ 오차의 계산

- 음과 양의 오차가 상쇄되지 않도록 절대값 또는 제곱하여 평균처리
- 오차(Error)값은 작을 수록 성능 우수

회귀 모델의 평가 지표

■ MAE(Mean Absolute Error)

$$\bullet \frac{\sum |\text{예측값} - \text{실제값}|}{N} = \frac{|(2-1)| + |(4-3)| + |(6-6)| + |(8-9)| + |(10-12)|}{5}$$

■ MSE(Mean Squared Error)

$$\bullet \frac{\sum (\text{예측값} - \text{실제값})^2}{N} = \frac{(2-1)^2 + (4-3)^2 + (6-6)^2 + (8-9)^2 + (10-12)^2}{5}$$

■ RMSE(Root Mean Squared Error)

$$\bullet \sqrt{\frac{\sum (\text{예측값} - \text{실제값})^2}{N}} = \sqrt{\frac{(2-1)^2 + (4-3)^2 + (6-6)^2 + (8-9)^2 + (10-12)^2}{5}}$$

■ RMSLE(Root Mean Squared Log Error)

$$\bullet \sqrt{\frac{\sum (\log(\text{예측값}+1) - \log(\text{실제값}+1))^2}{N}} = \sqrt{\frac{(\log 3 - \log 2)^2 + (\log 5 - \log 4)^2 + (\log 7 - \log 7)^2 + (\log 9 - \log 10)^2 + (\log 11 - \log 13)^2}{5}}$$

예측값	실제값
2	1
4	3
6	6
8	9
10	12